

YKS Cevap Anahtarı Örüntü Analizi ve Şık Tahmini: Bir “Sallamasyon” Çalışması

Hamza Yiğit Kültür

sallamasyon-yks — NVIDIA GH200 (Grace 72-core + H100)

20 Haziran 2026

Özet

Bu çalışma, 2018–2024 yılları arasındaki YKS (TYT ve AYT) sınavlarının cevap anahtarlarını analiz ederek, ÖSYM’nin doğru cevap dağılımında sömürülebilir bir istatistiksel örüntü olup olmadığını araştırır. 16 adet resmî sınav kitapçığı PDF’inden koordinat-tabanlı bir çıkarım yöntemiyle toplam **2034** geçerli cevap (İPTAL hariç) elde edilmiştir. Şık dağılımının düzgüne yakın olduğu (ki-kare = 3.35, anlamsız), ancak *ardışık aynı şıkkın belirgin biçimde nadir olduğu* (%13.14, rastgele beklenen %20) bulunmuştur. 2025 sınavı bağımsız değerlendirme (evaluation) seti olarak kullanılmış; istatistiksel baseline’lar ile dört sinir ağı mimarisi (MLP, CNN, GRU, Transformer) karşılaştırılmıştır. En iyi sonucu **GRU** (%24.88 ± 3.04) vermiştir; bu, rastgele tahminin (%19.93) üzerinde fakat mütevazı bir kazanımdır. Sonuçlar, YKS cevaplarının büyük ölçüde rastgele olduğunu, tek anlamlı sinyalin “tekrar kaçınması” olduğunu göstermektedir.

1 Giriş ve Motivasyon

Çoktan seçmeli sınavlarda, cevabı bilinmeyen sorularda boş bırakmak yerine istatistiksel olarak en olası şıkkı işaretlemek (halk arasında “sallamak”) yaygın bir stratejidir. Bu çalışmanın amacı, geçmiş YKS cevap anahtarlarından öğrenilebilecek bir örüntü olup olmadığını *dürüst ve tekrarlanabilir* biçimde test etmektir. Beklentimiz baştan düşüktü: iyi tasarlanmış bir sınavın cevap anahtarı, tahmin edilemez (rastgeleye yakın) olmalıdır. Bu rapor, bu beklentinin büyük ölçüde doğrulandığını ancak küçük bir istisnanın bulunduğunu belgeler.

2 Veri ve Çıkarım Yöntemi

Veri seti, ÖSYM’nin resmî sınav kitapçıklarından oluşur (2018–2024 eğitim, 2025 değerlendirme). Cevap anahtarları her PDF’in son sayfasında, çok sütunlu bir düzende ve üzerinde çapraz filigran (watermark) metni bulunan biçimde yer alır. Bu filigran, naif metin çıkarımını bozmaktadır.

Koordinat-tabanlı çıkarım. `pdftotext -bbox-layout` ile her kelimenin piksel koordinatları alınmış; tek harfli A–E hücrelerinin x koordinatları kümelenerek ders sütunları filigrandan bağımsız biçimde tespit edilmiştir. Her soru numarası, y koordinatına göre ilgili cevapla eşleştirilmiştir. Bu yöntem, naif yaklaşımın başarısız olduğu AYT 2022 (sütun dağılımı) ve filigran çakışması (TYT 2020, 18. soru) durumlarını çözmüştür. İptal edilen sorular (TYT 2019’da 1 adet) ayrıca işaretlenmiştir. Tüm 16 PDF, otomatik doğrulama katmanından (her ders için 1– N kesintisiz soru kontrolü) **sıfır uyarı** ile geçmiştir.


3 Keşifsel Analiz

3.1 Şık Dağılımı

Genel şık dağılımı düzgüne oldukça yakındır (Tablo 1, Şekil 1). Düzgün dağılıma karşı yapılan ki-kare testi $\chi^2 = 3.35$ değerini vermiştir; bu, $df = 4$ için %5 kritik değeri olan 9.49'un altındadır. Dolayısıyla “belirli bir şık daha sık çıkar” hipotezi istatistiksel olarak reddedilir. Pratik sonuç: her soruya kör biçimde tek bir şık (ör. “hep D”) işaretlemek, rastgeleye karşı anlamlı bir avantaj sağlamaz.

Tablo 1: Genel şık dağılımı (%), 2018–2024, $n = 2034$.

	A	B	C	D	E
Genel	19.27	20.40	20.50	20.99	18.83




Şekil 1: Genel şık dağılımı. Kırmızı kesikli çizgi rastgele beklentiyi (%20) gösterir. Tüm şıklar bu çizgiye yakındır.

Tablo 2: Ders bazlı şık dağılımı (%).

Ders	A	B	C	D	E
Edebiyat-Sosyal1	22.1	16.4	23.2	18.9	19.3
Fen	18.6	20.0	19.8	21.9	19.8
Matematik	18.8	21.6	20.9	20.8	17.9
Sosyal	17.2	21.3	20.7	20.1	20.7
Sosyal2	19.6	21.4	19.6	21.7	17.7
Türkçe	19.4	20.8	19.0	21.9	19.0

3.2 Ardışık Tekrar: Tek Gerçek Sinyal

En çarpıcı bulgu, ardışık (peş peşe) soruların aynı şıkka sahip olma oranıdır: **yalnızca** %13.14, rastgele beklenen %20'nin belirgin biçimde altında. Veri setinde gözlemlenen *maksimum ardışık tekrar* 3'tür; yani aynı şık asla 4 kez üst üste gelmemiştir. Bu, ÖSYM'nin cevap anahtarını oluştururken bilinçli ya da örtük olarak “tekrar kaçınması” uyguladığını düşündürür. Markov geçiş matrisinde (Şekil 2) bu durum, köşegen değerlerinin (aynı şıkka geçiş) düşük olmasıyla açıkça görülür. **Bu örüntü, bu çalışmadaki tek sömürülebilir sinyaldir.**



Şekil 2: Markov geçiş matrisi $P(\text{sonraki} \mid \text{önceki})$. Köşegen (aynı şıkka geçiş) tutarlı biçimde 0.20’nin altındadır; ortalama 0.131.

4 Veri Seti ve Eğitim Kurgusu

Veri. Ham veri, ÖSYM’nin 16 resmî sınav kitapçığı PDF’idir (TYT ve AYT, 2018–2025). Cevap anahtarları, koordinat-tabanlı bir çıkarıcı ile elde edilmiş ve $\{\text{yıl}, \text{sınav}, \text{ders}, \text{soru_no}, \text{şık}\}$ şemasında yapılandırılmıştır. Eğitim seti yalnızca **2018–2024**’tür: İPTAL edilen sorular çıkarıldıktan sonra **2034** cevap, 56 adet (yıl, sınav, ders) dizisinden oluşur. **2025** sınavı (291 cevap) eğitime hiç katılmayan bağımsız değerlendirme setidir.

Girdi temsili. Her cevap, $A-E$ için $\{0, 1, 2, 3, 4\}$ tamsayı etiketine eşlenir. Bir “dizi”, tek bir (yıl, sınav, ders) testinin soru sırasına göre dizilmiş şık etiketleridir (ör. TYT Matematik için 40 elemanlı). Ders adı bir kategorik öznitelik olarak gömme (embedding) ile temsil edilir.

Tahmin senaryosu. Bir dizide her pozisyondaki şık, geçmiş (bilinen) şıklardan tahmin edilir—“önceki cevaplar belli, sonrakini salla” senaryosu. Dizisel modeller *nedensel* (causal) çalışır: pozisyon i yalnızca $< i$ konumları görür, böylece geleceğe sızıntı olmaz.

5 Model Mimarileri

Tüm modeller PyTorch ile yazılmış ve NVIDIA GH200 üzerinde eğitilmiştir. Sinir ağlarının ortak hiperparametreleri: gömme/gizli boyut $d_{\text{model}} = 64$ (MLP’de gizli katman 128), optimizasyon AdamW (öğrenme oranı 2×10^{-3} , ağırlık çürümesi 10^{-3}), kayıp çapraz-entropi, dropout 0.3. Her model 10 farklı tohum (seed) ile eğitilip ortalama $\pm$ standart sapma raporlanır.

Baseline’lar (sinir ağı değil). (i) *Rastgele*: düzgün 5-sınıf tahmin. (ii) *En Sık Şık*: ders bazlı en sık şık her soruya verir. (iii) *Pozisyonel*: $P(\text{şık} \mid \text{ders}, \text{soru_no})$ argmax. (iv) *Markov*: $P(\text{sonraki} \mid \text{önceki})$ geçiş matrisi (Laplace düzeltmeli) ile argmax.

MLP. Tablo-tabanlı ileri-beslemeli ağ. Girdi: ders gömmesi (8 boyut) + normalize soru numarası + son üç şıkın gömmeleri (3×8). İki gizli katman (128, ReLU, dropout) ardından 5-sınıf softmax. Diziyi bütün olarak görmez; yalnızca yerel öznitelikleri kullanır.

CNN (nedensel). Şık dizisini token gömmeleri + konum gömmeleri + ders gömmesi ile temsil eder. İki adet 1-boyutlu evrişim katmanı (çekirdek 3, $d_{\text{model}} = 64$) uygulanır; *sol-pad* ile geleceğe bakması engellenir (nedensellik). Her pozisyon için 5-sınıf çıktı üretir.

GRU (nedensel). Aynı gömme girdisi üzerinde 2 katmanlı GRU (gizli boyut 64, dropout 0.3). RNN doğası gereği yalnızca geçmişe baktığı için nedensellik kendiliğinden sağlanır. Her zaman adımında 5-sınıf çıktı.

Transformer (nedensel). 2 kodlayıcı katmanı, 4 dikkat başlığı, ileri-besleme boyutu $4d_{\text{model}}$, GELU aktivasyonu. *Üçgensel nedensel maske* ile pozisyon i yalnızca $\leq i$ konumlara dikkat eder. Token, konum ve ders gömmeleri toplanarak girdi oluşturulur.

6 Değerlendirme Protokolü

Doğruluk tanımı. Bir modelin doğruluğu, 2025 test setinde doğru tahmin edilen soru sayısının toplam soru sayısına oranıdır ($\text{doğruluk} = \frac{\text{doğru tahmin}}{\text{toplam soru}}$), yüzde olarak verilir. Rastgele beklenti 5 şık için %20'dir.


Tur sayısı. Sinir ağları (MLP, CNN, GRU, Transformer) rastgele başlatmaya duyarlı olduğundan, her biri 10 **bağımsız tohum (seed)** ile eğitilip değerlendirilir; tabloda *ortalama $\pm$ standart sapma* (10 tur üzerinden) raporlanır. Baseline'lar deterministiktir (Rastgele hariç), tek değer verir. Hiçbir sonuç tek-atış değildir.

7 Sonuçlar

Dört baseline ile dört sinir ağı 2025'te karşılaştırılmıştır.

Tablo 3: 2025 değerlendirme doğrulukları. "Eğitim" sütunu eğitim setindeki doğruluğu gösterir; sinir ağlarındaki yüksek eğitim doğruluğu aşırı öğrenmeye (overfitting) işaret eder.

Model	Tür	2025 Doğruluk (%)	Eğitim (%)
Rastgele	Baseline	19.93	—
EnSıkŞık	Baseline	21.99	—
Pozisyonel	Baseline	18.56	—
Markov	Baseline	21.65	—
MLP	Sinir Ağı	18.25 $\pm$ 1.57	45.0
CNN	Sinir Ağı	20.03 $\pm$ 2.15	96.5
GRU	Sinir Ağı	24.88$\pm$3.04	96.1
Transformer	Sinir Ağı	22.41 $\pm$ 2.18	96.6



Şekil 3: Model karşılaştırması (2025). Gri: baseline, mavi: sinir ağı. Hata çubukları 10 tohumun standart sapmasıdır. Kırmızı çizgi rastgele (%20) seviyesini gösterir.

8 Tartışma

Sonuçlar (Tablo 3, Şekil 3) birkaç net mesaj verir:

- **Aşırı öğrenme baskındır.** MLP, CNN, GRU ve Transformer eğitim setinde %45–%97 doğruluğa ulaşırken değerlendirmede %18–%25 bandında kalır. Veri küçük (2034 örnek) ve gerçek sinyal zayıf olduğundan, yüksek kapasiteli modeller eğitim verisini ezberler.
- **Pozisyonel bilgi işe yaramaz.** Pozisyonel baseline (%18.56) rastgelenin dahi altındadır; “*k*. soru genelde X şıkkıdır” diye bir kural yoktur.
- **Tek kazanç tekrar kaçınmasından gelir.** Markov (%21.65) ve onun zengin versiyonu olan GRU (24.88 ± 3.04) baseline’ı geçer. GRU’nun avantajı, ardışık tekrar kaçınması örüntüsünü Markov’dan daha esnek modellemesinden kaynaklanır.
- **Kazanım mütevazı ve gürültülüdür.** En iyi model bile rastgelenin yalnızca ~ 5 puan üzerindedir ve standart sapması yüksektir (± 3). Bu, pratikte “her boş soruda $\sim 5\%$ ekstra isabet” demektir; garanti değil, beklenen değer.

Donanım notu. Modeller NVIDIA GH200 üzerinde eğitildi. Dürüst olmak gerekirse, problemin ölçeği bu donanımın kapasitesinin çok altındadır; tüm model zoo saniyeler içinde eğitilmiştir. GH200 burada bir gereklilik değil, erişilebilir bir araç olarak kullanılmıştır.

9 Sonuç

YKS cevap anahtarları, tasarım amacına uygun biçimde *büyük ölçüde tahmin edilemezdir*. Şık dağılımı düzgüne yakındır ve konuma bağlı bir örüntü yoktur. Tespit edilebilen tek yapısal özellik, aynı şıkkın peş peşe nadiren tekrarlanmasıdır; bu da en fazla birkaç puanlık bir avantaj sağlar. “Sallamasyon” için pratik öneri sadedir: *bilinen komşu cevaplardan farklı bir şık seçmek*, kör rastgeleye göre küçük ama tutarlı bir kazanç getirir—gerisi şanstır.

Tekrarlanabilirlik. Tüm kod ve veri açık biçimde `scripts/` ve `data/processed/` altındadır. İşlem hattı: `extract_answers.py` → `analyze.py` → `train.py` → `build_report.py`.