

YKS “Sallamasyon” II: Şık Dengeleme Sinyali ve Sızıntısız Imputation Değerlendirmesi

sallamasyon-yks
NVIDIA GH200 (Grace 72-core + H100) üzerinde

20 Haziran 2026

Özet

Bu ikinci raporda, YKS cevap anahtarlarında ilk raporun yakaladığı tek sinyalin (ardışık tekrar kaçınması) ötesine geçerek daha güçlü ve pratik bir yapı keşfediyoruz: **şık dengeleme**. Her sınav testinde A–E şıklarının düzgüne çok yakın biçimde dağıldığını (test-içi şık-sayısı standart sapması, gerçek/rastgele oranı ≈ 0.54); tekrar kaçınmasının yalnızca komşuda değil 2–3 soruluk bir pencerede sürdüğünü; ve aynı şıkın peş peşe gelme olasılığının her tekrarda keskin biçimde düştüğünü (1 üst üste sonrası %14, 2 sonrası %6, 3 sonrası %0 — yani 4’lü tekrar hiç görülmez) gösteriyoruz. Bu sinyalleri sömürmek için gerçek sallamasyon senaryosuna uygun, **sızıntısız bir imputation** (boşluk doldurma) değerlendirme protokolü kuruyoruz: bir testte soruların bir kısmı bilinir, kalanı tahmin edilir ve yalnızca gizli pozisyonlardaki isabet ölçülür. Tüm modeller yalnızca 2018–2024’te eğitilir; 2025 sınavı kesinlikle dokunulmamış test setidir. Tüm sinyalleri birleştiren modeller, bilinen oran %90 iken rastgele tahmine göre +13 **puana kadar** kazanç sağlar. İlginç biçimde, GH200 üzerinde eğitilen BERT-tarzı derin bir model bu basit istatistiksel modelleri geçememektedir; dahası, sinyaller büyük ölçüde *örtüştüğü* için hepsini tek modelde toplamak ekstra kazanç getirmez.

1 Motivasyon ve İlk Rapordan Farkı

İlk raporda şık dağılımının düzgüne yakın olduğunu ve tek sömürülebilir sinyalin ardışık tekrar kaçınması (%13, rastgele %20) olduğunu bulmuştuk; en iyi model rastgelenin yalnızca birkaç puan üzerindeydi. Bu raporda iki ilerleme var: (i) daha güçlü bir yapısal sinyal (*dengeleme*) keşfediyoruz, (ii) bunu gerçek sınav davranışına uyan ve veri sızıntısına karşı titizlikle korunan bir değerlendirme ile ölçüyoruz.

2 Sızıntı (Data Leakage) Güvencesi

Sonuçların geçerliliği için 2025 verisinin hiçbir biçimde eğitime karışmaması kritiktir. Aşağıdaki garantiler bir doğrulama scripti (`check_leakage.py`) ile otomatik olarak teyit edilmiştir:


- Eğitim seti (`all_answers.json`) yalnızca 2018–2024 içerir; 2025 *yoktur*.
- Ders sözlüğü (`subject_vocab`) yalnızca eğitimden türetilir; değerlendirmede görülmeyen bir ders olursa `<UNK>`’e düşürülür.
- Tüm modeller `fit()` ile yalnızca eğitimi görür.
- Imputation sırasında model yalnızca *bilinen* pozisyonların gerçek şikkını görür; *gizli* pozların şikkına asla erişemez.
- Hybrid modelin α ağırlığı yalnızca eğitim içi başarıyla seçilir (2025 kullanılmaz).

3 Keşfedilen Sinyaller (yalnızca eğitim verisi)


Tablo 1 bulguları özetler. En güçlü sinyal şık dengelemedir: her testte 5 şıkın sayısı neredeyse eşittir (Şekil 1). Tekrar kaçınması komşuluğun ötesine taşar (Şekil 2): aynı şık 2–3 soru arayıla da beklenenden seyrek görülür.

Tablo 1: Eğitim (2018–2024) üzerinde keşfedilen sinyaller.

Sinyal	Ölçüm	Güç
Şık dengeleme (std oranı)	$1.20 / 2.23 = 0.54$	Güçlü
Tekrar gap =1	13.1% (rastgele 20%)	Güçlü
Tekrar gap =2	16.9%	Orta
Tekrar gap =3	17.3%	Orta
Run-length: 2 üst üste sonrası	6.2% aynı (rastgele 20%)	Güçlü
Run-length: 3 üst üste sonrası	0.0% aynı (asla 4'lü yok)	Güçlü
2. derece Markov	in-sample 27.1%	Zayıf (ezber)
Yerel çeşitlilik (5'li)	7.0% (rastgele 3.8%)	Orta



Şekil 1: Şık dengeleme sinyali. Mavi: gerçek test-içi şık-sayısı standart sapması (yıl bazlı). Kırmızı kesikli: aynı uzunlukta rastgele dizilerin beklenen std'i. Gerçek değerler tutarlı biçimde çok daha düşüktür; yani şıklar dengeli dağıtılır.



Şekil 2: Pencere-bazlı tekrar kaçınması. Aynı şıkkın g soru arayla tekrar etme oranı; kısa mesafelerde ($g = 1, 2, 3$) rastgele %20’nin altındadır.

4 Sallamasyon (Imputation) Değerlendirmesi


Gerçek senaryo: öğrenci soruların bir kısmını *doğru bilir*, kalanını *boş bırakıp tahmin eder*. Her test için soruların rastgele % k ’sı “bilinen” kabul edilir (gerçek şıkkı modele verilir), kalanı gizlenir. Model gizli pozisyonları tahmin eder; yalnızca bu pozisyonlardaki isabet ölçülür. Her ayar 300 rastgele maskeleme denemesiyle ortalananır.

Tablo 2: Gizli pozisyon doğruluğu (%), 2025 test seti. Her sütun farklı bilinen oranı. Kalın: o sütunun en iyisi.

Model	k =50%	k =70%	k =85%	k =90%
Rastgele	20.07±3.4	20.03±4.3	19.96±6.3	19.66±7.0
GlobalFreq	21.88±2.4	21.90±3.7	21.67±5.8	21.54±7.2
Markov	20.93±2.8	20.66±3.9	20.55±5.9	20.62±7.3
Dengeleme	21.40±3.6	23.13±4.4	26.54±6.9	30.30±8.5
PencereKaçın	23.02±2.6	23.75±3.7	24.71±5.7	25.50±7.7
Hybrid	22.56±3.2	25.18±4.4	29.66±6.7	32.62±8.8
SmartHybrid	23.74±3.3	26.36±4.3	29.51±6.6	31.07±7.8
Unified	23.49±3.4	26.15±4.6	30.23±6.5	32.32±7.9
MaskedBERT	21.47±2.9	21.61±4.1	22.30±6.2	22.50±7.6

Tablo 3: Rastgele tahmine karşı kazanç (puan), 2025.

Model	k =50%	k =70%	k =85%	k =90%
Markov	+0.85	+0.62	+0.58	+0.97
Dengeleme	+1.32	+3.09	+6.58	+10.64
PencereKaçın	+2.95	+3.72	+4.75	+5.84
Hybrid	+2.49	+5.15	+9.70	+12.97
SmartHybrid	+3.66	+6.33	+9.55	+11.41
Unified	+3.42	+6.12	+10.27	+12.67
MaskedBERT	+1.39	+1.57	+2.33	+2.84



Şekil 3: Bilinen oran arttıkça modellerin gizli-pozisyon başarısı. Dengeleme ve Hybrid, bilinen oran yükseldikçe belirgin biçimde ayrışır; çünkü ne kadar çok cevap bilinirse kalan “şık bütçesi” o kadar kısıtlanır.

5 Tartışma

- **Dengeleme, kazancın asıl kaynağıdır.** Tek başına Markov (komşuluk) yalnızca ~ 1 puan katarken, dengeleme bilinen oran %90’da +10.6 puan sağlar. Sezgi: bir testte 5 şık eşit dağıldığından, bilinen cevaplar arttıkça kalan boşlukların hangi şık olması gerektiği giderek belirginleşir.
- **Tekrar sinyalleri güçlüdür ama BİRBİRİYLE ÖRTÜŞÜR.** Aynı şıkkın peş peşe gelmemesi üç farklı biçimde ölçülebilir: pencere-kaçınma (gap profili), run-length (2 üst üste sonrası %6, 3 sonrası %0) ve 1. derece Markov. Bunların hepsi temelde *aynı* olguyu yakalar; bu yüzden “her şeyi bilen” birleşik model (UNIFIED), tek tek bileşenlerden anlamlı ekstra kazanç sağlamaz. Nitekim ağırlık seçimi (train’de) run-length bileşenini büyük ölçüde sıfırlamıştır.
- **Pencere-kaçınma, düşük bilinen oranda öne çıkar.** Komşu şıkları cezalandıran model (PENCEREKAÇIN), az soru bilindiğinde (%50) dengelemeden daha iyidir (+2.95 vs +1.32); çünkü dengeleme bütçesi henüz belirsizken yerel komşuluk daha bilgilendiricidir. Yüksek bilinen oranda ise dengeleme baskındır.
- **En iyi model, bilinen orana göre değişir.** %50–%70 aralığında SMARTHYBRID (dengeleme + pencere-kaçınma) lider (+3.66 / +6.33); %85–%90’da saf HYBRID/UNIFIED öne geçer (+10 ila +13). Çoğu gerçek aday %50–%80 aralığında olduğundan, pratikte SMARTHYBRID en faydalı modeldir.
- **Etki, bilinen orana çok duyarlıdır.** Az soru bilen için kazanç küçük (%50’de $\sim +3$), çoğu soruyu bilip birkaç boşluğu sallayan için büyüktür (%90’da $\sim +13$). Bu, gerçek sınav davranışına tam oturur.
- **Daha karmaşık her zaman daha iyi değildir.** GH200 üzerinde eğitilen BERT-tarzı maskeli Transformer, açık formüllü modellerin gerisinde kalır. Küçük veri (56 test dizisi) derin modelin bu kısıtları güvenilir öğrenmesini engeller; elle kodlanmış kurallar daha güçlüdür.

6 Sonuç

Şık dengeleme, YKS cevap anahtarlarındaki en güçlü ve en pratik yapısal sinyaldir. Pratik öneri nettir: *bildiğin soruları işaretledikten sonra, kalan boşlukları o testte henüz az çıkmış şıklara dağıt.* Bu strateji, özellikle soruların çoğunu bilen bir aday için kör rastgeleye göre 10 puanı aşan bir beklenen kazanç sağlar—ve tüm bu kazanç, 2025’e hiç bakmadan, yalnızca geçmiş yılların yapısından öğrenilmiştir.

Tekrarlanabilirlik. İşlem hattı: `check_leakage.py` → `analyze_signals.py` → `eval_impute.py` → `build_report2.py`.