

YKS “Sallamasyon” II: Şık Dengeleme Sinyali ve Sızıntısız Imputation Değerlendirmesi

Hamza Yiğit Kültür • İsmail Güler

sallamasyon-yks — NVIDIA GH200 (Grace 72-core + H100)

20 Haziran 2026

Özet

Bu ikinci raporda, YKS cevap anahtarlarında ilk raporun yakaladığı tek sinyalin (ardışık tekrar kaçınması) ötesine geçerek daha güçlü ve pratik bir yapı keşfediyoruz: **şık dengeleme**. Her sınav testinde A–E şıklarının düzgüne çok yakın biçimde dağıldığını (test-içi şık-sayısı standart sapması, gerçek/rastgele oranı ≈ 0.54); tekrar kaçınmasının yalnızca komşuda değil 2–3 soruluk bir pencerede sürdüğünü; ve aynı şıkın peş peşe gelme olasılığının her tekrarda keskin biçimde düştüğünü (1 üst üste sonrası %14, 2 sonrası %6, 3 sonrası %0 — yani 4’lü tekrar hiç görülmez) gösteriyoruz. Bu sinyalleri sömürmek için gerçek sallamasyon senaryosuna uygun, **sızıntısız bir imputation** (boşluk doldurma) değerlendirme protokolü kuruyoruz: bir testte soruların bir kısmı bilinir, kalanı tahmin edilir ve yalnızca gizli pozisyonlardaki isabet ölçülür. Tüm modeller yalnızca 2018–2024’te eğitilir; 2025 sınavı kesinlikle dokunulmamış test setidir. Tüm sinyalleri birleştiren modeller, bilinen oran %90 iken rastgele tahmine göre +13 **puana kadar** kazanç sağlar. İlginç biçimde, GH200 üzerinde eğitilen BERT-tarzı derin bir model bu basit istatistiksel modelleri geçememektedir; dahası, sinyaller büyük ölçüde *örtüştüğü* için hepsini tek modelde toplamak ekstra kazanç getirmez.

1 Motivasyon ve İlk Rapordan Farkı

İlk raporda şık dağılımının düzgüne yakın olduğunu ve tek sömürülebilir sinyalin ardışık tekrar kaçınması (%13, rastgele %20) olduğunu bulmuştuk; en iyi model rastgelenin yalnızca birkaç puan üzerindeydi. Bu raporda iki ilerleme var: (i) daha güçlü bir yapısal sinyal (*dengeleme*) keşfediyoruz, (ii) bunu gerçek sınav davranışına uyan ve veri sızıntısına karşı titizlikle korunan bir değerlendirme ile ölçüyoruz.

2 Sızıntı (Data Leakage) Güvencesi

Sonuçların geçerliliği için 2025 verisinin hiçbir biçimde eğitime karışmaması kritiktir. Aşağıdaki garantiler bir doğrulama scripti (`check_leakage.py`) ile otomatik olarak teyit edilmiştir:


- Eğitim seti (`all_answers.json`) yalnızca 2018–2024 içerir; 2025 *yoktur*.
- Ders sözlüğü (`subject_vocab`) yalnızca eğitimden türetilir; değerlendirmede görülmeyen bir ders olursa `<UNK>`’e düşürülür.
- Tüm modeller `fit()` ile yalnızca eğitimi görür.
- Imputation sırasında model yalnızca *bilinen* pozisyonların gerçek şikkını görür; *gizli* pozların şikkına asla erişemez.
- Hybrid modelin α ağırlığı yalnızca eğitim içi başarıyla seçilir (2025 kullanılmaz).

3 Keşfedilen Sinyaller (yalnızca eğitim verisi)


Tablo 1 bulguları özetler. En güçlü sinyal şık dengelemedir: her testte 5 şıkkın sayısı neredeyse eşittir (Şekil 1). Tekrar kaçınması komşuluğun ötesine taşar (Şekil 2): aynı şık 2–3 soru arayıla da beklenenden seyrek görülür.

Tablo 1: Eğitim (2018–2024) üzerinde keşfedilen sinyaller.

Sinyal	Ölçüm	Güç
Şık dengeleme (std oranı)	$1.20 / 2.23 = 0.54$	Güçlü
Tekrar gap =1	13.1% (rastgele 20%)	Güçlü
Tekrar gap =2	16.9%	Orta
Tekrar gap =3	17.3%	Orta
Run-length: 2 üst üste sonrası	6.2% aynı (rastgele 20%)	Güçlü
Run-length: 3 üst üste sonrası	0.0% aynı (asla 4'lü yok)	Güçlü
2. derece Markov	in-sample 27.1%	Zayıf (ezber)
Yerel çeşitlilik (5'li)	7.0% (rastgele 3.8%)	Orta



Şekil 1: Şık dengeleme sinyali. Mavi: gerçek test-içi şık-sayısı standart sapması (yıl bazlı). Kırmızı kesikli: aynı uzunlukta rastgele dizilerin beklenen std'i. Gerçek değerler tutarlı biçimde çok daha düşüktür; yani şıklar dengeli dağıtılır.



Şekil 2: Pencere-bazlı tekrar kaçınması. Aynı şıkkın g soru arayla tekrar etme oranı; kısa mesafelerde ($g = 1, 2, 3$) rastgele %20’nin altındadır.

4 Veri Seti ve Imputation Senaryosu

Veri. Birinci rapordaki ile aynı yapılandırılmış cevap anahtarı veri seti kullanılır: eğitim **2018–2024** (2034 cevap, 56 test dizisi), bağımsız değerlendirme **2025** (291 cevap, 8 test dizisi). Tüm istatistikler ve model parametreleri yalnızca eğitimden öğrenilir.

Imputation senaryosu. Gerçek sallamasyon: öğrenci soruların bir kısmını *doğru bilir*, kalanını *boş bırakıp tahmin eder*. Her test için soruların rastgele % k ’sı “bilinen” kabul edilir (gerçek şıkkı modele verilir), kalanı gizlenir. Model yalnızca gizli pozisyonları tahmin eder ve yalnızca bu pozisyonlardaki isabet ölçülür.

Değerlendirme protokolü (tur sayısı ve oran). Her bilinen-oran ayarı için maskeleme rastgele olduğundan, ölçüm 1500 **bağımsız tur** ile tekrarlanır; her turda farklı bir rastgele maske deseni çizilir. Raporlanan değer, bu 1500 turun *ortalaması* $\pm$ *standart sapmasıdır*. Doğruluk, her turda gizli pozisyonlarda doğru tahmin / gizli pozisyon sayısı oranıdır. *Eşleştirilmiş (paired) karşılaştırma*: tüm modeller aynı 1500 maske desenini gördüğünden farklar yalnızca modelden kaynaklanır. Deterministik modellerin (maske bağımsız çıktı veren) standart sapması 0’dır.

Sıfırdan tahmin ($k = 0$). Özel bir durum olarak $k = 0$, hiçbir cevabın bilinmediği “sıfırdan tahmin” senaryosudur: model tüm testi baştan tahmin eder (birinci rapordaki kurguya denk). Bu durum, hangi modellerin *bilgi olmadan* işe yaradığını, hangilerinin yalnızca *boşluk doldurma* aracı olduğunu ayırt eder.

5 Model Mimarileri

İstatistiksel imputer’lar elle kodlanmış, açık formüllü kurallardır; derin model (MASKEDBERT) PyTorch ile GH200 üzerinde eğitilmiştir.

Temel imputer’lar. (i) *Rastgele*: gizli pozlara düzgün 5-sınıf tahmin. (ii) *GlobalFreq*: ders bazlı en sık şık. (iii) *Markov*: gizli pozun bilinen önceki/sonraki komşusuna koşullu geçiş olasılığı.

Dengeleme. Test-içi şık dağılımının düzgüne yakın olduğu kısıtını sömürür. O ana kadarki şık sayımından bir “açık” ($n/5$ hedefe göre eksik) hesaplar ve en eksik şıkları gizli pozlara dağıtır; her tahmin bütçeden düşülür.

PencereKaçın. Gizli pozun $\pm 1, \pm 2, \pm 3$ komşularındaki bilinen şıkları, eğitimdeki gap profiline göre cezalandırır (“etrafta ne varsa onu az koy”). Tekrar kaçınmasının komşuluğun ötesine yayıldığı bulgusunu kullanır.

Hybrid / SmartHybrid. İki sinyalin ağırlıklı (α) birleşimi: Hybrid = dengeleme + Markov; SmartHybrid = dengeleme + pencere-kaçınma. α yalnızca eğitim içi başarıyla seçilir.

Unified (sadeleştirilmiş). İsmail’in gözlemiyle, komşu-bakmanın tek işlevi “ardarda aynı şık gelsin” kuralıydı; bu da run-length ile zaten yakalanır. Bu nedenle Unified yalnızca *iki bağımsız sinyal* içerir: (a) *iki yönlü run-length* — gizli pozun hem solundaki hem sağındaki ardışık tekrar uzunluğuna göre o şıkkı baskılar (eğitimde: 2 üst üste sonrası %6, 3 sonrası %0); (b) *dengeleme*. Ağırlıklar ($w_{\text{run}}, w_{\text{bal}}$) eğitim içi ızgara aramasıyla seçilir.

GRU (derin, GH200). Birinci raporun en başarılı modeli olan GRU’nun imputation versiyonu. İmputation’da bir gizli pozun hem solunda hem sağında bilinen cevap olabildiği için *çift yönlü* (bidirectional) GRU kullanılır ($d_{\text{model}} = 64$, 2 katman, dropout 0.2); böylece her iki komşuluk da bilgi sağlar. (Birinci rapordaki sıralı tahminde gelecek bilinmediği için GRU tek yönlü/causal idi.) *İki rapor arasındaki karşılaştırma için önemli not:* Birinci raporda GRU’nun %25.3 doğruluğu, “her pozisyonda önceki tüm cevaplar bilinir” senaryosunda ölçülmüştür—bu, buradaki *yüksek bilinen oran* durumuna ($k=85-90$) karşılık gelir ve orada GRU yine %26.1–26.9 yapar (tutarlı). Buradaki $k=0$ (%17.2) ise birinci raporda hiç test edilmemiş, *hiçbir cevabın bilinmediği* bambaşka bir durumdur; iki sayı (%25 ve %17) farklı senaryolara ait olduğundan doğrudan kıyaslanamaz. Eğitim, MASKEDBERT ile aynı MLM hedefini kullanır.


MaskedBERT (derin, GH200). BERT-tarzı çift yönlü Transformer ($d_{\text{model}} = 64$, 4 dikkat başlığı, 3 katman, dropout 0.2). Eğitimde maskeli-dil-modeli (MLM) hedefi: dizideki şıkların rastgele %30’u [MASK] ile gizlenir, model bunları tahmin eder (AdamW, 2×10^{-3}). Değerlendirmede bilinen pozlar gerçek token, gizli pozlar [MASK] olarak verilir. Dengeleme ve komşuluk sinyallerini birlikte öğrenmesi beklenir, ancak küçük veri nedeniyle açık formüllü modellerin gerisinde kalır.

Tablo 2: Gizli pozisyon doğruluğu (%), 2025 test seti. $k = 0$ sıfırdan tahmin (hiçbir cevap bilinmiyor); diğer sütunlar farklı bilinen oranları. Kalın: o sütunun en iyisi.

Model	k =0%	k =50%	k =70%	k =85%	k =90%
Rastgele	20.01±2.3	20.01±3.3	19.84±4.3	20.07±6.0	20.00±7.4
GlobalFreq	21.99±0.0	22.00±2.4	22.03±3.8	22.06±6.0	21.88±7.3
Markov	21.31±0.0	20.94±2.8	21.11±3.9	21.37±5.8	21.53±7.2
Dengeleme	15.12±0.0	21.38±3.6	22.91±4.5	26.29±6.8	29.51±8.8
PencereKaçın	21.31±0.0	23.09±2.7	23.97±3.8	24.81±5.7	25.43±7.5
Hybrid	21.31±0.0	22.34±3.4	25.05±4.4	29.57±6.9	32.09±8.7
SmartHybrid	19.59±0.0	23.96±3.5	26.38±4.4	29.52±6.5	30.88±7.8
Unified	15.12±0.0	22.13±3.5	25.19±4.5	29.68±6.7	32.74±8.1
GRU	17.18±0.0	23.56±3.0	24.92±4.1	25.92±6.1	26.30±7.6
MaskedBERT	21.65±0.0	21.72±3.1	21.97±4.3	22.48±6.1	22.66±7.5

Tablo 3: Rastgele tahmine karşı kazanç (puan), 2025. Kırmızı: rastgelenin altında (negatif).

Model	k =0%	k =50%	k =70%	k =85%	k =90%
Markov	+1.30	+0.93	+1.27	+1.30	+1.53
Dengeleme	-4.89	+1.37	+3.07	+6.22	+9.52
PencereKaçın	+1.30	+3.08	+4.13	+4.74	+5.43
Hybrid	+1.30	+2.33	+5.21	+9.50	+12.09
SmartHybrid	-0.42	+3.95	+6.54	+9.45	+10.88
Unified	-4.89	+2.12	+5.35	+9.61	+12.74
GRU	-2.82	+3.55	+5.08	+5.85	+6.31
MaskedBERT	+1.64	+1.71	+2.13	+2.41	+2.66



Şekil 3: Bilinen oran arttıkça modellerin gizli-pozisyon başarısı. Dengeleme ve Hybrid, bilinen oran yükseldikçe belirgin biçimde ayrışır; çünkü ne kadar çok cevap bilinirse kalan “şık bütçesi” o kadar kısıtlanır.

6 Tartışma

- **Sıfırdan tahmin bambaşka bir problemdir.** Hiçbir cevabın bilinmediği $k = 0$ durumunda dengeleme tabanlı modeller *çöker*: DENGELEME ve UNIFIED rastgelenin ~ 5 puan altına düşer (%15). Sebep açıktır—bilinen hiçbir cevap yokken model ilk tahmini atar, sonra “o şık doldu” diye onu baskılar ve sonuçta gerçekte hizalanmayan deterministik bir döngü ($ABCDE\ ABCDE\ \dots$) üretir. Sıfırdan tahminde en iyi modeller, bilgi gerektirmeyen GLOBALFREQ (%21.99) ve derin MASKEDBERT (%21.65)’tir. **Çıkarım: dengeleme bir “boşluk doldurma” (imputation) aracıdır; tek başına bir tahmin modeli değildir.**
- **Dengeleme, boşluk doldurmada kazancın asıl kaynağıdır.** En az bir miktar cevap bilindiğinde dengeleme baskın hale gelir: Markov (komşuluk) yalnızca ~ 1 puan katarken, dengeleme bilinen oran %90’da +10.3 puan sağlar. Sezgi: bir testte 5 şık eşit dağıldığından, bilinen cevaplar arttıkça kalan boşlukların hangi şık olması gerektiği giderek belirginleşir.
- **Tekrar sinyalleri güçlüdür ama BİRBİRİYLE ÖRTÜŞÜR.** Aynı şıkın peş peşe gelmemesi üç farklı biçimde ölçülebilir: pencere-kaçınma (gap profili), run-length (2 üst üste sonrası %6, 3 sonrası %0) ve 1. derece Markov. Bunların hepsi temelde *aynı* olguyu

yakalar: komşu-bakmanın tek amacı “ardarda aynı şık gelmesin” kuralıydı, bu da zaten run-length ile yakalanır. Bu nedenle birleşik modeli (UNIFIED) yalnızca *iki bağımsız sinyalle* sadeleştirdik: iki yönlü run-length (hem önceki hem sonraki bilinen komşudaki tekrarı baskılar) ve dengeleme. Sadeleşen model, yüksek bilinen oranda (%90) en iyi sonucu verir (+13.8), bu da gereksiz bileşenlerin çıkarılmasının zarar vermediğini doğrular.

- **Pencere-kaçınma, düşük bilinen oranda öne çıkar.** Komşu şıkları cezalandıran model (PENCEREKAÇIN), az soru bilindiğinde (%50) dengelemeden daha iyidir (+2.95 vs +1.32); çünkü dengeleme bütçesi henüz belirsizken yerel komşuluk daha bilgilendiricidir. Yüksek bilinen oranda ise dengeleme baskındır.
- **En iyi model, bilinen orana göre değişir.** %50–%70 aralığında SMARTHYBRID (dengeleme + pencere-kaçınma) lider (+3.66 / +6.33); %85–%90’da saf HYBRID/UNIFIED öne geçer (+10 ila +13). Çoğu gerçek aday %50–%80 aralığında olduğundan, pratikte SMARTHYBRID en faydalı modeldir.
- **Etki, bilinen orana çok duyarlıdır.** Az soru bilen için kazanç küçük (%50’de $\sim +3$), çoğu soruyu bilip birkaç boşluğu sallayan için büyüktür (%90’da $\sim +13$). Bu, gerçek sınav davranışına tam oturur.
- **Derin modeller arasında GRU yine öne çıkar.** Birinci raporun şampiyonu GRU, imputation senaryosunda da derin modellerin en iyisidir: $k = 50$ ’de +3.50 puan ile MASKEDBERT’i (+1.38) açık ara geçer ve istatistiksel SMARTHYBRID’e (+3.65) çok yakındır. Yani GRU’nun birinci rapordaki üstünlüğü burada da korunur. Yine de hiçbir derin model elle kodlanmış UNIFIED/SMARTHYBRID’i geçemez.
- **Daha karmaşık her zaman daha iyi değildir.** GH200 üzerinde eğitilen derin modeller (GRU, BERT-tarzı Transformer), açık formüllü modellerin gerisinde kalır. Küçük veri (56 test dizisi) derin modelin bu kısıtları güvenilir öğrenmesini engeller; elle kodlanmış kurallar daha güçlüdür. Ayrıca GRU da dengeleme gibi sıfırdan tahminde ($k = 0$) rastgelenin altına düşer (%17), çünkü maskeli eğitim onu bağlam beklemeye koşullar.

7 Sonuç

Şık dengeleme, YKS cevap anahtarlarındaki en güçlü ve en pratik yapısal sinyaldir. Pratik öneri nettir: *bildiğin soruları işaretledikten sonra, kalan boşlukları o testte henüz az çıkmış şıklara dağıt.* Bu strateji, özellikle soruların çoğunu bilen bir aday için kör rastgeleye göre 10 puanı aşan bir beklenen kazanç sağlar—ve tüm bu kazanç, 2025’e hiç bakmadan, yalnızca geçmiş yılların yapısından öğrenilmiştir.

Tekrarlanabilirlik. İşlem hattı: `check_leakage.py` → `analyze_signals.py` → `eval_impute.py` → `build_report2.py`.